









Santiago Pereira
Brandon Reyes
Giovanni Santos
Gabriela Mazariegos

PROYECTO 3: ENTREGA 3.



METODOLOGÍA




PIPELINE IMPLEMENTADO

Se utilizó StandardScaler para la normalización


Modelos:

- Ridge
- Lasso
- Árbol de Decisión)



BÚSQUEDA DE HIPERPARÁMETROS

- GridSearchCV con validación cruzada 5-fold
- Optimización con MSE negativo
- Procesamiento paralelo (n_jobs=-1)





RESULTADOS MODELOS DE REGRESIÓN



MEJOR MODELO

- Árbol de Decisión:
 - $R^2 = 0.1965$
 - $RMSE = 8.97$
 - $MAE = 5.36$
- Ridge y Lasso:
 - $R^2 \approx 0.13$



MEJORAS

- Mejora significativa con optimización
- Árbol: $0.186 \rightarrow 0.196$

MODELOS DE CLASIFICACIÓN



Se evaluaron tres modelos: Logistic Regression, Random Forest, Decision Tree

Todos con rendimiento excepcional:


Accuracy: 99.98%



Precision: 99.98%

Recall: 100%

F1-Score: 99.99%

Matrices de confusión muestran solo
3 falsos positivos





OPTIMIZACIÓN DE HIPERPARÁMETROS

Árbol de Decisión (regresión):

- Mejores parámetros:
 - max_depth=7
 - min_samples_leaf=4
 - min_samples_split=10
- Tiempo de ejecución: 980 segundos

Ridge y Lasso:


- Optimización mucho más rápida (<1 segundo)
- Mínima mejora en rendimiento

JUSTIFICACIÓN DEL MODELO RECOMENDADO




PARA CLASIFICACIÓN: RANDOM FOREST

- Maneja mejor la variabilidad de datos
- Mejor generalización para datos nuevos
- Mayor interpretabilidad (importancia de variables)
- Reduce sobreajuste mediante ensemble



PARA REGRESIÓN: ÁRBOL DE DECISIÓN OPTIMIZADO

- Mejor R^2 (0.1965)
- Aunque R^2 es bajo, indica complejidad del problema



CONCLUSIONES

- 01. Problema de clasificación es más simple que el de regresión**
- 02. Optimización mejoró principalmente el Árbol de Decisión**